

Magic: The Gathering

•Carnets•



Introducción

Este proyecto propone utilizar tecnicas de Deep Learning para predecir el Games in Hand Win Rate (win rate cuando la carta esta en mano), empleando unicamente metricas de draft disponibles publicamente.

Para lograrlo, se trabajo con un dataset de 376 cartas que contiene metricas reales de miles de partidas jugadas. De entre todas las variables, el modelo se entreno para predecir el GIH WR utilizando unicamente cinco metricas observables durante la fase de seleccion de cartas, sin acceso alguno al color, rareza o texto de la carta.

Dataset

Tenemos dos grandes grupos de variables. Por un lado, las metricas de draft: cuantas veces aparecio la carta en sobres (# Seen), en que posicion promedio fue vista por ultima vez (ALSA), cuantas veces fue elegida (# Picked) y en que posicion (ATA). Estas cuatro variables nos cuentan la historia de como se comporta una carta durante la fase de seleccion, si los jugadores la toman temprano, si gira en la mesa sin que nadie la quiera, o si pasa desapercibida.

Por otro lado, las metricas de partida: cuantas veces se jugo (# GP), en que porcentaje de mazos se incluyo (% GP), y una familia de porcentajes de victoria segmentados por contexto: cuando la carta estuvo en la mano inicial (OH WR), cuando fue robada durante la partida (GD WR), cuando estuvo en la mano en cualquier momento (GIH WR) y cuando nunca aparecio (GNS WR).

Metodologia

Se utilizo un pipeline estructurado en seis fases

PREPARACIONES, DATASET, FEATURE ENGINEERING, MODELO, ENTRENAMIENTO, EVALUACION

El target GIH WR es un valor numerico continuo. Por lo tanto, la tarea se clasifica como regresion. Esto determina:


- Funcion de activacion de la ultima capa: linear
- Funcion de perdida (loss): MSE (Mean Squared Error)
- Metrica de evaluacion: RMSE (Root Mean Squared Error)

Limpieza: conversion de strings con formato "40.4%" y "-10.2pp" a valores float, eliminacion de filas con valores nulos.

Normalizacion: se aplico Z-score a todas las features, para evitar problemas de escala.

Split: 80% entrenamiento (287 cartas), 20% prueba (72 cartas), con validation_split=0.2 durante el entrenamiento.

Se evaluo el modelo sobre el conjunto de prueba (72 cartas no vistas durante el entrenamiento) utilizando las metricas MSE y RMSE.



Construimos un matriz de dispersion para visualizar las relaciones entre nuestras variables y obtuvimos que: en todas las intersecciones que involucran # Seen (cartas vistas) y # Picked (cartas elegidas), los puntos no forman una masa unica, sino que se dividen en 3 o 4 franjas horizontales y verticales muy separadas entre si.

ALSA y ATA Redundantes: el cruce entre ambas variables forma una linea diagonal ascendente casi perfecta y muy estrecha.

Al observar el cruce de % GP (porcentaje de partidas jugadas) frente a ALSA (turno promedio en que se ve), los puntos forman una diagonal gruesa que baja de izquierda a derecha. A medida que una carta esta disponible mas tarde en el sobre, su probabilidad de ser incluida en el mazo principal baja dramaticamente.

En % GP, la mayoría de los puntos esta aglomerada entre el 60% y el 100%, pero hay cartas esparcidas cerca del 0% al 20%. En GIH WR, hay puntos solitarios que superan el 65% o caen por debajo del 42%, alejados de la masa central. Además, dentro de cada banda de rareza, los cruces entre # Picked/# Seen y GIH WR forman nubes sin inclinacion clara, ser una carta muy elegida no garantiza estadisticamente que gane mucho.

Resultados

Realizando cambios como quitar ALSA o ATA ya que eran redundantes segun lo visto en la matriz o filtrar las cartas con % GP < 10% o GIH WR extremo de nuestro modelo termino empeorando nuestro modelo, por lo que finalmente dejamos las 5 features sin filtrar, siendo este el mejor.

Metrica	Valor
MSE (Loss)	5.81
RMSE	2.41 pp

Un RMSE de 2.41 puntos porcentuales significa que el modelo predice el win rate de una carta con un margen de error promedio de aproximadamente ± 2.4 pp. En otras palabras, si una carta tiene un GIH WR real de 55.0%, el modelo la predecira aproximadamente entre 52.6% y 57.4%.

Conclusiones

1. Es posible predecir el desempeño de una carta usando solo datos de draft. Cinco variables todas disponibles antes de jugar una sola partida fueron suficientes para que el modelo alcanzara un RMSE de 2.41 pp sobre datos no vistos.
2. El modelo no necesita entender las reglas del juego. Sin acceso al texto, color, rareza ni habilidades de las cartas, la red neuronal infirio patrones exclusivamente a partir del comportamiento de seleccion de los jugadores.
3. La distincion regresion vs clasificacion es fundamental. La eleccion de activation='linear', loss='mse' y RMSE como metrica fue consecuencia directa de identificar el target como numerico continuo.

Mejoras a Futuro

1. Experimentar con arquitecturas alternativas: Probar configuraciones con mas o menos capas y neuronas.
2. Explorar otras tareas de regresion con el mismo dataset: Predecir ALSA (que tan codiciada es una carta) usando % GP y GIH WR como features o Predecir IWD (Improvement When Drawn) para identificar cartas de alto impacto o transformar el problema en clasificacion como predecir Rarity a partir de metricas de desempeño.
3. Implementar una forma distinta de dividir los datos, llamada validacion cruzada, dividiendolo en grupos, por ejemplo, 5 grupos, 4 grupos para entrenar y 1 grupo de examen.